小祝的量化因子笔记 3th

1 Wolfe Research 两个情绪因子的定义、数据研究。

2 Literature Review 看在 A 股因子、量价因子相关 paper、论坛。

3 投资组合构建或者机器学习相关的方法、文章。

Part 1: Multi-factor Investing

1. BlackRock

A. Macroeconomic Factors

Economic Growth	Risk associated with global economic growth ✧ *Broad-market equity index returns*
Real Rates	Risk of bearing exposure to real interest rate changes ✧ *Inflation-linked bond returns*
Inflation	Risk of bearing exposure to changes in nominal prices ✧ *Return of long nominal bonds, short inflation-linked bonds portfolio*
Credit	Risk of default or spread widening ✧ *Return of long corporate bonds, short nominal bonds portfolio*
Emerging Markets	Risk that emerging sovereign governments will change capital market rules ✧ *Basket of EM equity premia, EM CDX, and EM FX*
Commodity	Risk associated with commodity markets ✧ *Weighted GSCI Commodity index returns*

B. Style Factors

Value	Stocks which are inexpensive relative to fundamentals
Low Size	Companies with smaller market capitalizations
Momentum	Securities displaying positive price trends
Quality	Companies with strong balance sheets and stable earnings
Dividend Yield	Stocks with a high dividend relative to price
Min Vol	Securities with low historical price volatility
Carry[1]	Income incentive to hold riskier securities

[1] Carry (套息): Diven by a risk premium embedded in asset prices to incent potential investors to hold riskier securities.

2. Wolfe Research：The Silk Road to China

A. 中国传统的选股因子(P25-36):

a) Value factors perform well in China，similar to the US market. P25

Book-to-market

Figure 25 Book-to-Market

A) China, Rank IC

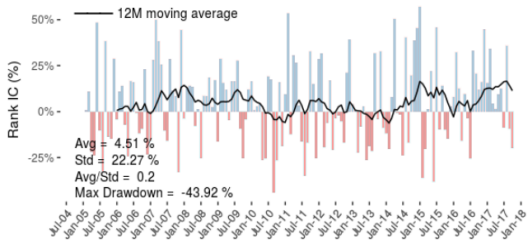

B) China, Cumulative Performance (L/S Quintile Portfolio)

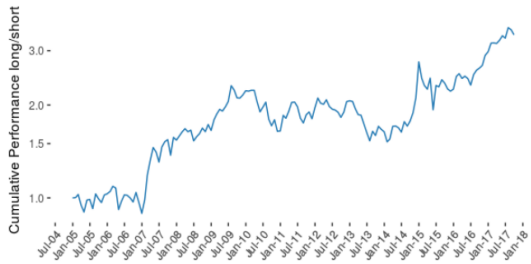

Earnings yield

Figure 26 Earnings Yield

A) China, Rank IC

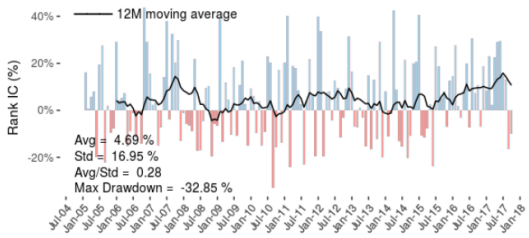

B) China, Cumulative Performance (L/S Quintile Portfolio)

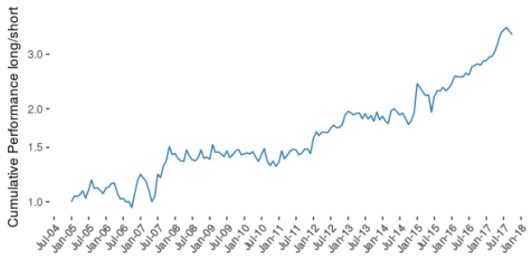

Dividend yield

Figure 27 Dividend Yield

A) China, Rank IC

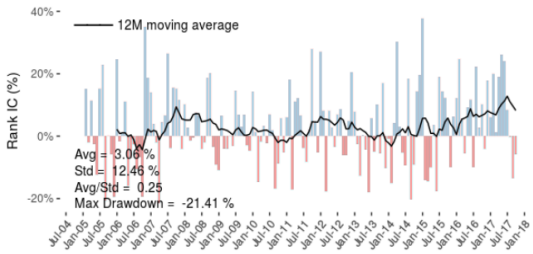

B) China, Cumulative Performance (L/S Quintile Portfolio)

Value 总体上有较慢的衰减和低的换手率（autocorrelation 大于 95%）:

Figure 30 Low Turnover and Slow Decay

A) IC Decay for the Composite Value Factor

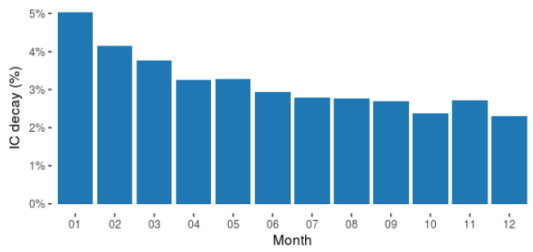

B) Signal Autocorrelation

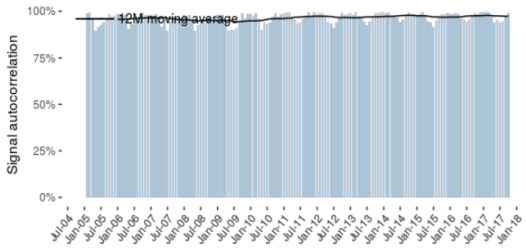

b) **Growth factors** also perform well in China. P29

Year over Year EPS	*Year over Year Revenue*
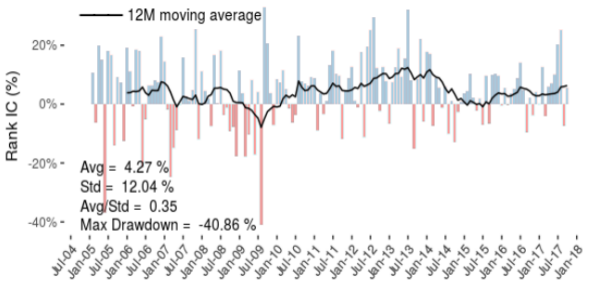	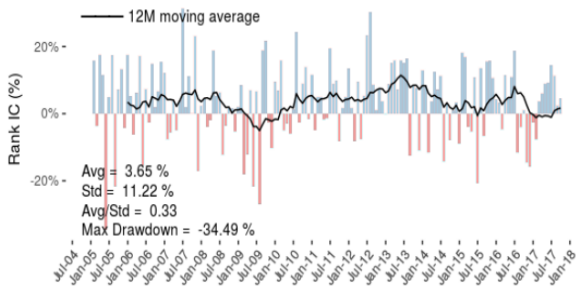

相较 value, growth 衰减更快,*不过 combined 后增强效果明显(因为两个因子相关度低)。*

c) **Quality** as a style differs significantly from China to developed markets. P31

ROE	*Year over Year Change in ROE (ROE Momentum)*
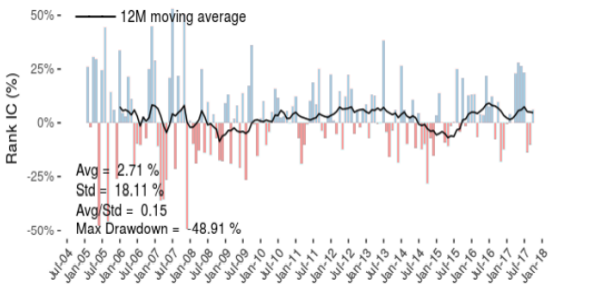	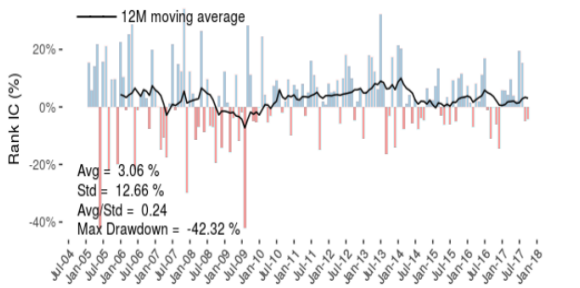

违背直觉地，根据与违约风险相关的因子（Merton's distance to default），长期来看在中国最安稳的公司表现其实逊色于风险最高的公司（可能因为国企杠杆高但违约风险很小）。

在像中国这样快速发展的经济体中，*profitability 的变化量比绝对量更重要*，ROE Momentum factor 比 ROE 因子收益高 60%。

d) **Analyst sentiment factors** are highly predictive of future stock returns. P33

Figure 37 Composite Sentiment Factor Performance

A) Rank IC **B) Cumulative Performance (L/S Quintile Portfolio)**

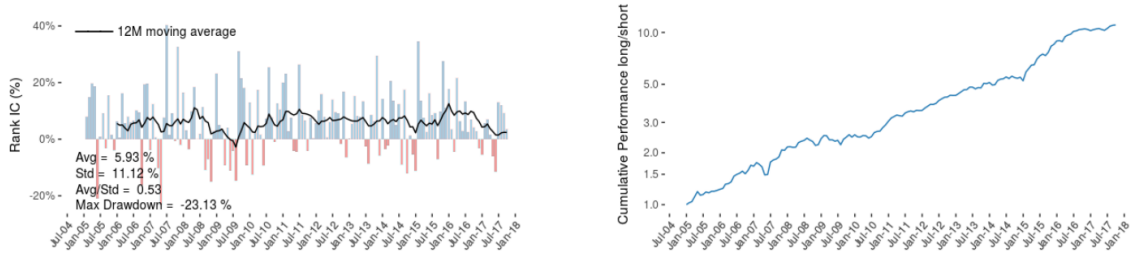

标准的 sentiment 因子如 target price implied returns（衡量 implied upside of each stock）*和 earnings revision*（类似 momentum/trend-following signal）*产生了超乎寻常的表现*，且 combine 两个因子效果会更显著。此外，使用 *local vendor* 如 Wind 也会 increases alpha.

Sentiment 产生了 1.8x 的夏普比，并伴随仅很小的回撤，这甚至能成为独立的交易策略。

虽 combine 后的 sentiment 比 value 换手率更高且更快衰减，但其预测力仍较可观。

e) Mean reversal and price momentum. P35

Figure 41 Reversal Factor Performance

One Month Reversal

A) One Month Reversal (Descending), Rank IC

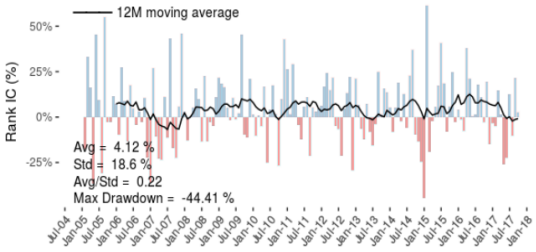

B) IC Decay, One Month Reversal Factor

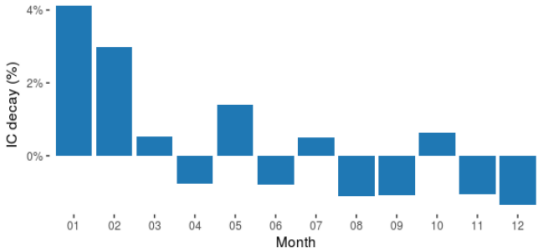

与日本相似而与大多数其他市场不同的是，*在中国没有 price momentum 存在，但有很强的 mean reversal pattern，并且表现极为出色*。

标准的 One-month reversal factors 会很典型地衰减迅速并在一个多月后失去预测能力。

Figure 42 Reversal Signal Calculated with Different Horizon

Reversals with different horizon

A) Long/short Quintile Annualized Returns

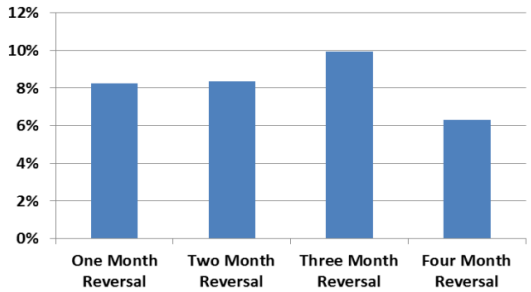

B) Average Signal Autocorrelation

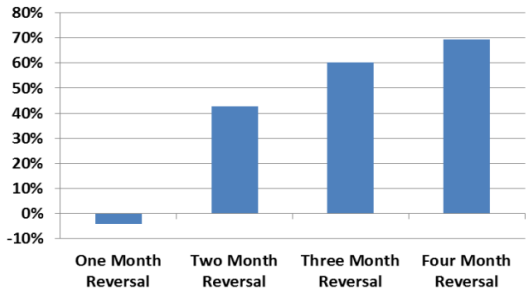

用过去 two-month 和 three-month 计算的 reversal factor 甚至优于 one-month reversal signal，更重要的是，拉长周期会换来换手率的降低（体现在更高的 signal autocorrelation）。尤其 three-month 的 reversal 拥有平均每月 10%的 rank IC，并伴随着 60%的 signal serial correlation，*意味着比 growth factor 还更高的预测能力和更低的换手率。*

另一种 capture 均值回归的方法是通过 lottery factor（定义为 lowest daily return in the past 21 trading days），但总体效果不如 three-month reversal.

f) Low Volatility factor performs well in China, even in the 2015 market rally. P39

Figure 44 Low Volatility Factor Performance

Low Volatility

A) Rank IC

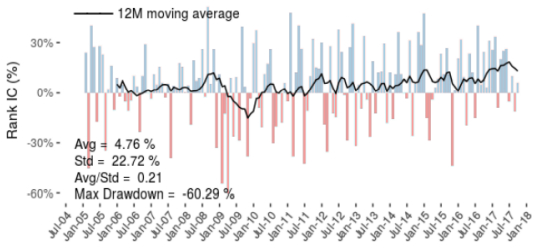

B) IC Decay

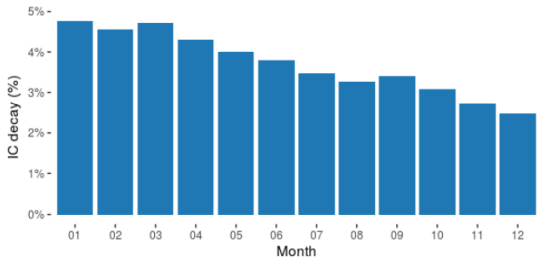

因为 low volatility 和市场高度负相关，所以在牛市时效果会很差。

g) 等权重的基准模型 BM（Benchmark Model）

•	Value	book to price | earnings yield | dividend yield
•	Growth	YoY quarterly earnings growth | YoY quarterly revenue growth
•	Analyst Sentiment	target price implied return | earnings revision
•	Quality	ROE momentum
•	Mean-Reversal	three-month total return
•	LowVol	realized one-year daily volatility

平均的 rank IC 超过 9%，甚至比对好的单因子高出 50%。Risk adjusted IC 也类似。

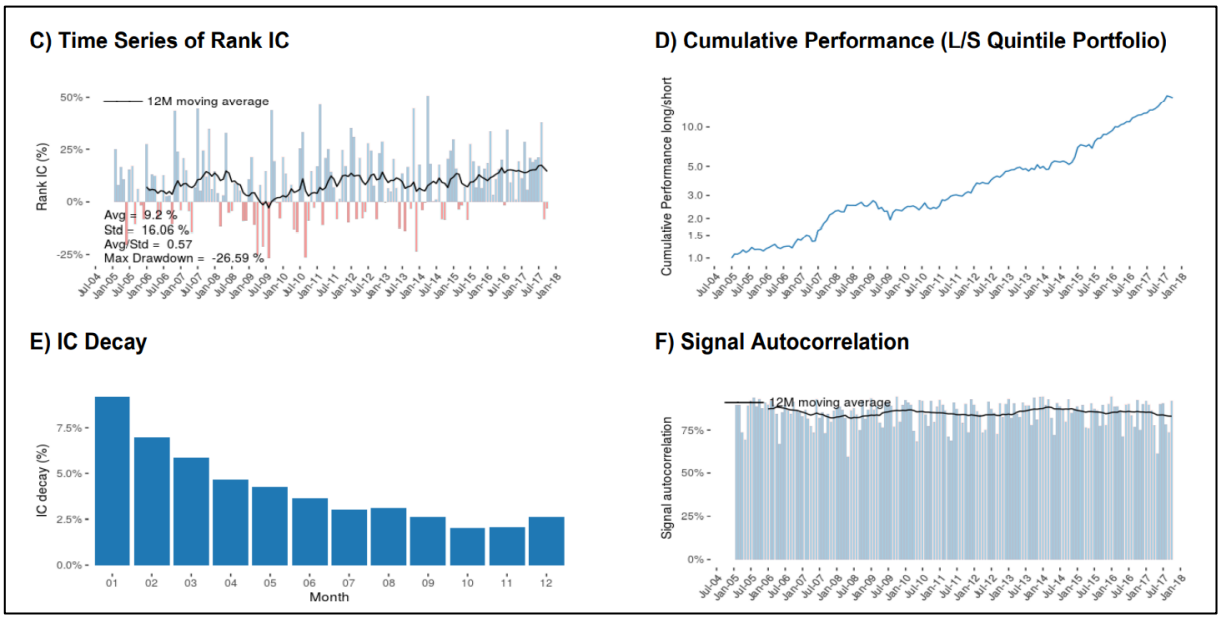

Rank IC 时间序列（12M moving average）表现小结：

因子大类	名称	Avg	Std	Avg/Std	Max D	IC 衰减	Autocorrelation
价值	Book-to-Market	4.51%	22.27%	0.20	-43.92%	很慢：12 个月 0.02	**95%**
	Earnings Yield	4.69%	16.95%	0.28	-32.85%		
	Dividend Yield	3.06%	12.46%	0.25	**-21.41%**		
	算术平均	4.09%	17.23%	0.24			
成长	YOY EPS	4.27%	12.04%	0.35	-40.86%	中等：4 个月 0.02	
	YOY Revenue	3.65%	11.22%	0.33	-34.49%		
	算术平均	3.96%	11.63%	0.34			
质量	ROE	2.71%	18.11%	0.15	-48.91%		
	ROE Momentum	3.06%	12.66%	0.24	-42.32%		
	算术平均	2.89%	15.39%	0.20			
情绪	Composite Sentiment	**5.93%**	**11.12%**	**0.53**	-23.13%	较慢：8 个月 0.02	65%
均值回归	One-month	4.12%	18.60%	0.22	-44.41%	较快：2 个月 0.02	2-m40% 3-m60%
低波动率	Low Volatility	4.76%	22.72%	0.21	-60.29%	**最慢：12 个月 0.025**	
基准模型	BM	9.20%	16.06%	0.57	-26.59%	12 个月 0.025	80%

B. **行业中性 Sector Neutralization[2](P43-36):**

除了 GICS 的行业分类，Wind 提供了一个当地的行业划分标准由 CITICS 制定，称为 CITICS-ICS 或 CITICS 行业分类标准，其具体划分请见附录"**Wind CITICS-ICS 行业划分**"。

经过 CITICS-ICS neutralized 的基准模型 BM 产生了 2.0x 的 sharp ratio。

Figure 52 BM Model Performance Comparison, Different Neutralization Techniques

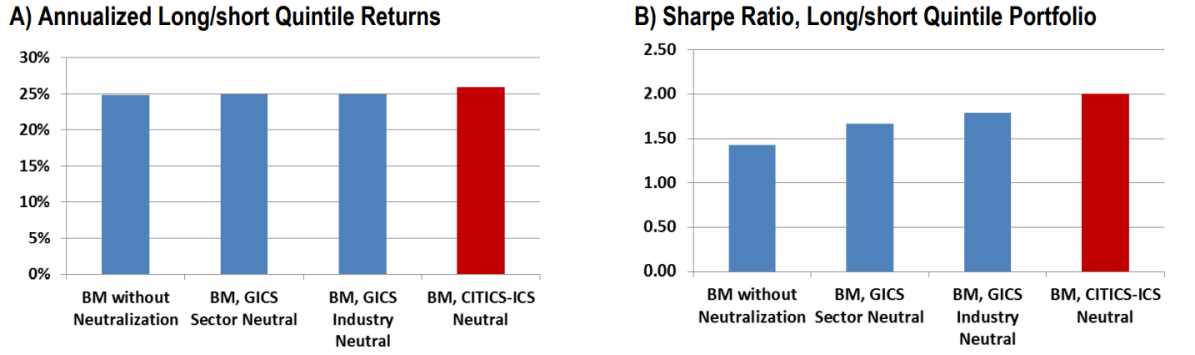

如我们所预料的，sharp ratio 的增加主要来自于减少的风险。

Figure 53 Significant Risk Reduction from Neutralization, BM

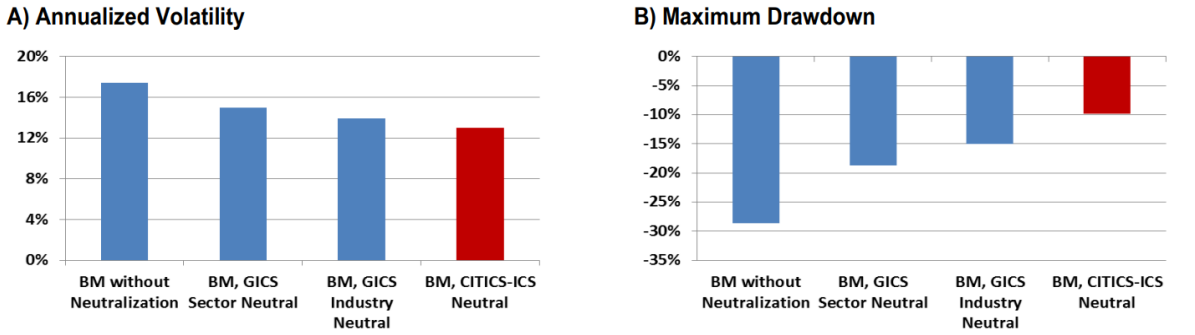

BM 与 Neutralized BM 对比:

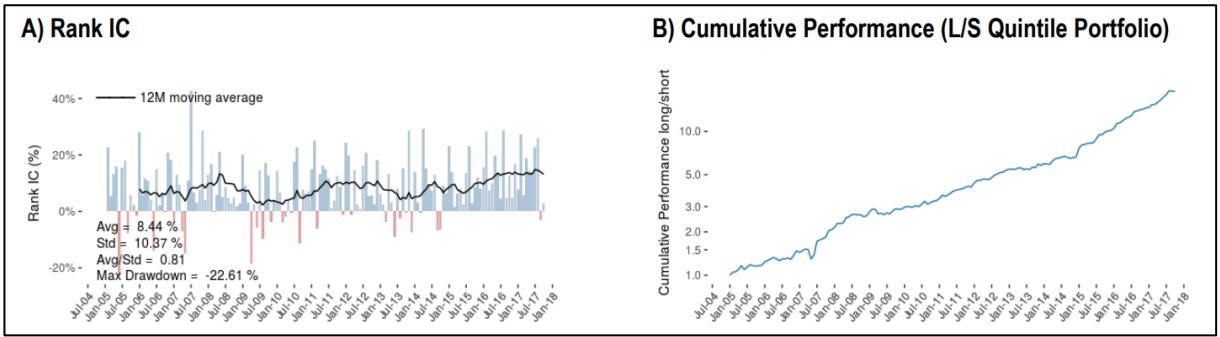

Model	Avg	Std	Avg/Std	Max D	Sharpe ratio (L/S)	最大回撤	年化收益
BM	**9.20%**	16.06%	0.57	-26.59%	1.45	-28.5%	24.90%
Neutralized BM	8.44%	**10.37%**	**0.81**	**-22.61%**	**2.00**	**-9.9%**	**25.94%**

[2] Neutralization 最简单的方法是，因子被 combine 在一起成为多因子模型之前，normalize 每个行业的每个因子。

C. Wolfe Research 情绪因子研究

一、 Target price implied returns（衡量 implied upside of each stock）

$$Target\ price\ implied\ returns = \frac{E_t^A(P_{t+1})}{P_t} - 1$$
$$= \frac{target\ price}{current\ price} - 1 = \frac{TP}{P} - 1$$

其中$E_t^A(P_{t+1})$是分析师在 t 月对价格 one-year-ahead 的期望，P_t是 t 月股票价格。

会议提及 Paper 其数据来源[9]：I/B/E/S unadjusted detail history price target dataset. I/B/E/S 指 Institutional Brokers' Estimate System，由 Refinitiv 提供，其前身是汤森路透。

能找到最相近的替代数据是 **Wind 一致预测目标价（效果并不好）**，定义为全部机构预测目标价的算术平均值，其周期为 180 天—以当日向前寻找 180 天内各个机构对某公司某报告期最新一次的预测记录。

构造因子（目标价-收盘价）评分排序每月等权选前 50 支股票（也试了前 25、100、250 或按市值、流通市值、自由流通市值加权，但结果都差不多），下图为回测之一：

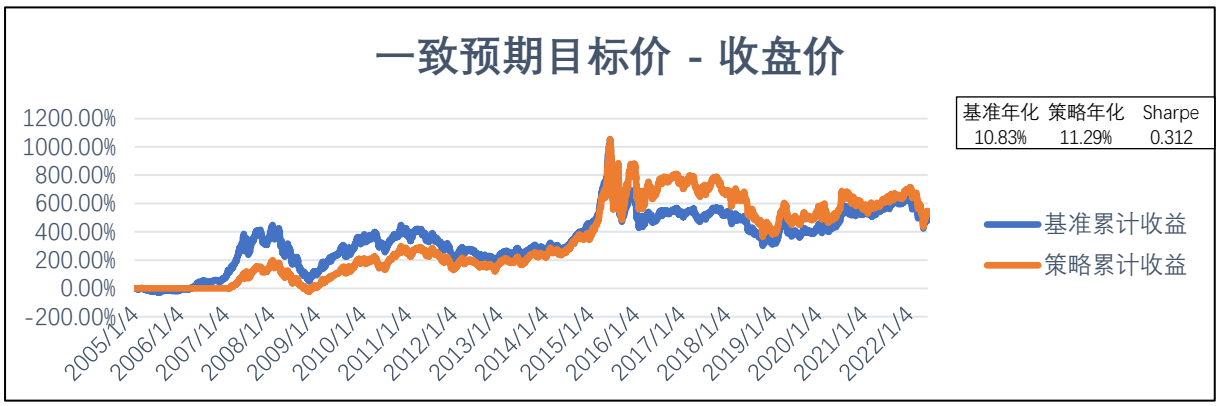

二、 Earnings revision[3]（类似 momentum/trend-following signal）

分析师盈利修正的超额收益在资产定价的论文中是较为著名的异象，一般称为盈利修正后的价格漂移（Post Forecast Revision Drift，简称 PFRF）。

道琼斯工业发布的研究《在亚洲，盈利修正重要吗》和《应用盈利修正策略于亚洲基本面因子》中，同样使用了汤森路透机构经纪人预测系统(I/B/E/S)数据库，选取了七个泛亚市场（中日韩等）的每股盈利普遍预测数据[4]，研究以每股盈利变动[5]和每股盈利扩散[6]为基础。

国盛证券在《多因子系列之十五：分析师盈利修正后的股价漂移》中，选取了 **Wind 底层数据库中的中国 A 股盈利预测明细数据**（约 50 万条）。分析师在每篇报告中都对未来几个报告期的盈利预测，最后只选取对当年盈利的预测。其定义为：

(当期盈利预测 – 上期盈利预测)/上期盈利预测的绝对值

---

[3] Earning revision 在 Wolfe Research 官方因子库的定义：NTM EPS revision, 3M.

[4] 道琼斯检索了来自 Factset 的 I/B/E/S 预测数据，其中历史预测根据股份分拆等企业行动作出调整。I/B/E/S 预测数据按合并和非合并基础提供，道琼斯使用的是大多数分析师过去就每个期间在他们预测中报告的数据。

[5] 每股盈利变动按当前 EPS 预测中值减之前三个月 EPS 预测中值，除以之前三个月 EPS 预测中值的绝对值计算。

[6] 每股盈利扩散按过去三个月 EPS 扩散总和计算，其中每个月的 EPS 扩散按该月 EPS 预测向上修正数减向下修正数，除以 EPS 预测总数计算。

尝试找到的替代数据是 Wind **机构预测每股盈利**[7]，但数据存在一些缺陷，造成了无法回测较长时段等问题。以下是过去仅仅 3 年的最好回测[8]：

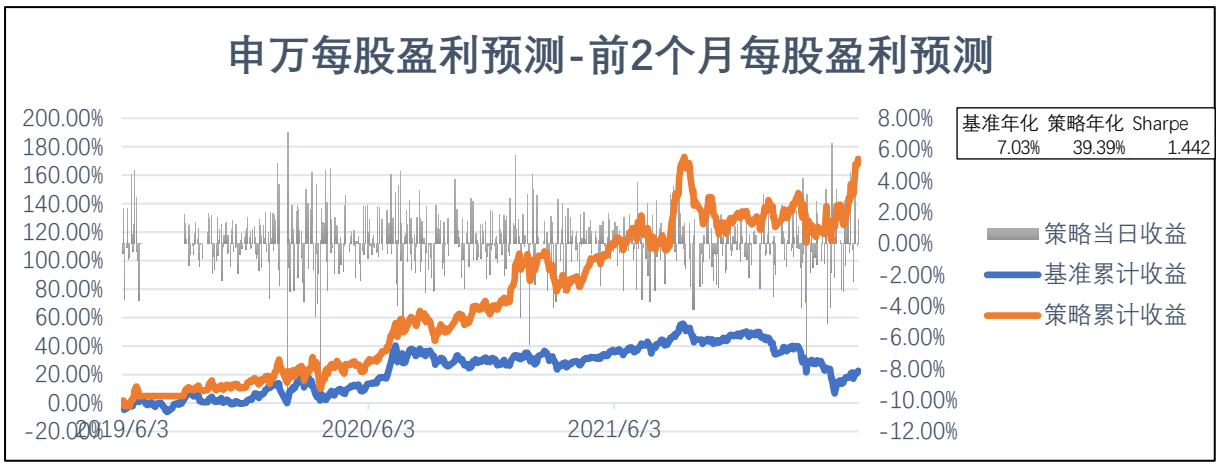

如果要复现盈利修正因子需要注意以下问题：

1. 每一报告期的盈利预测都要寻找**相同机构**对股票池的预测数据，且每篇报告存在**多个报告期预测值**。
2. 前后分析师有时其实不可比，因为**同一机构的分析师可能存在更换**。这些情况占样本占比较小，为缓解此问题可剔除两次盈利预测间隔 180 天的样本。
3. 一些报告**首次覆盖**，或在过去 180 天**没有同期的盈利预测**，无法计算盈利修正。
4. 由于**微利股**[9]的存在，有些盈利修正幅度达到 10 倍以上，故缩尾处理数据。
5. 股票池**历史成分是动态变化的**，根据之前的研究，中证 500 大约有 1500 只股票入选过成分股。

针对第 5 点，统计了下中证 500 成分股不同年份与 2021 年重复的数量：

2008	2009	2010	2011	2012	2013	2014
81	88	88	110	112	123	151
2015	**2016**	**2017**	**2018**	**2019**	**2020**	**2021**
168	185	221	272	328	399	500

大部分分析师对盈利预测偏乐观，所以更多情况是随着时间将盈利预测回调或保持不变，所以当向上修正时说明有相当积极的信息出现，**故该类因子仍较可能有效**，虽然相关数据处理起来相对麻烦。

或许是主要取决于分析师主观因素，策略**换手率相对较高**。此外，可以推断此类因子**与其他种类因子的相关度会相对较低**，基于这点很可能提升模型的总体表现。

对于因子的选择，由于 Selection bias 的存在、因子间的高相似度等现象，选取所有历史表现最好的因子进行组合可能无法保证未来表现，而后文的 Winton Capital 部分提供了另一种思路。

---

[7] 但终端数据并不好用，一是机构的每股盈利预测数据不够整齐，二是回测因子间隔的灵活度不够。

[8] 回测结果和选择的机构、预测间隔等因素都有关系，该回测结果存在过拟合可能性。

[9] 微利股：每股收益 0.1 元以下的股票，经常是企业通过会计处理手段做出来的，表现了企业处于危机边缘，但仍有翻盘机会，所以有时会使盈利修正大幅提高。

D. Wolfe 机器学习模型 LEAP China-A

LEAP 模型（see Luo, et al [2017c]）基于 proprietary model boosting philosophy，分 3 部分：

1 Nonlinear RF-CART[10] 目标是捕捉最显著的 nonlinear pattern	1. 用随机森林 RF 来实施 feature selection 或者说 factor selection. 2. 将 top factors 喂给传统的分类回归树 CART 模型来区分好坏。
2 Linear Multifactor Model 因子选择是基于 filter 和 wrapper 方法	1. 来自不同 style bucket 的 factors 会基于各自的 univariate performance 被 filtered. 2. 去除高度相关的因子。 3. 修改过的 Fama-MacBeth regression 会被用作 wrapper 来每次消除一个因子。变量选择的过程计算量很大。 4. 一旦因子 list 在某个节点被选择完成，就 re-estimate 过去 120 个月每个 linear factor and nonlinear terminal nodes 的 payoff.
3 Style Rotation & Bayesian Shrinkage	1. 对于最终的因子收益预测，应用 Bayesian shrinkage 技术来获得每个因子长期（或短期）平均更鲁棒的估计。

我们把来自 LEAP 模型的算法用于中国 A 股：

- 因为 MSCI China A Index 开始于 2004 年 12 月，所以只有 13 年的历史数据。
- 由于有限的 A 股历史，我们采用 60 个月滚动窗口来训练 LEAP China-A 模型，而不像其他区域那样用 120 个月的滚动窗口。
- 针对 LEAP China-A，我们用 CITICS-CIS Level One 行业标准来做中性化处理。
- 考虑到很强的春节效应，我们 shrink factor return predictions for February towards the past five-year moving average.

因此，LEAP China-A 本质上遵循同样的 machine learning philosophy and suite of algorithms，只是微调了少许来适应中国 A 股。

Figure 66 LEAP-China Model Performance

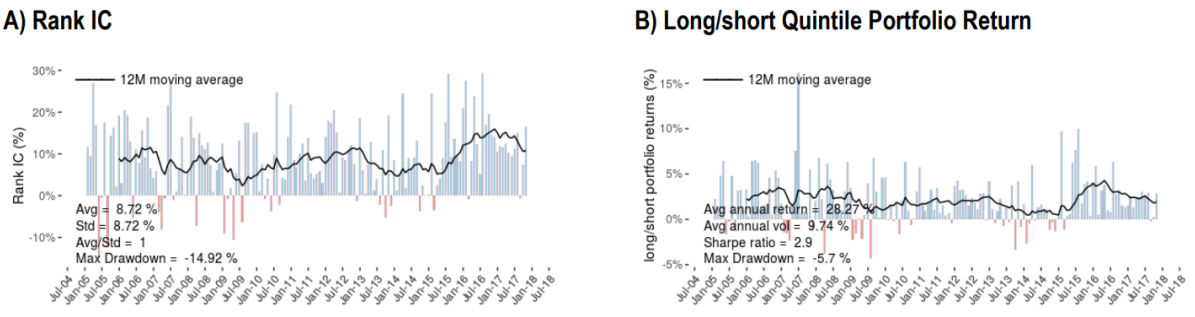

Sources: Bloomberg Finance LLP, FTSE Russell, S&P Capital IQ, Thomson Reuters, Wind, MSCI, Wolfe Research Luo's QES

模型 IC 时间序列数据和夏普比等对比：

Model	Avg	Std	Avg/Std	Max D	Sharpe ratio (L/S)	最大回撤	年化收益
BM	**9.20%**	16.06%	0.57	-26.59%	1.45	-28.5%	24.90%
Neutralized BM	8.44%	10.37%	0.81	-22.61%	2.0	-9.9%	25.94%
LEAP China-A	8.72%	**8.72%**	**1.00**	**-14.92%**	**2.9**	**-5.7%**	**28.27%**

[10] 本质上 RF-CART 是个 classification 模型，尝试区分出 outperformers。为避免 look-ahead bias，在每个投资的时间节点上 fit.

3. Winton Capital（国内名为元盛）

Winton 很大程度是 hypothesis-driven 的，一个研究员会从一个真实世界的想法出发，搜寻数据去验证其正确性。当基于这个想法出产交易信号时，目标则是与现有的策略：

1. 低相关（low correlation）
2. 低换手率（low turnover）
3. 以及一个正的但不高的 Sharpe ratio，一般在 0.3-0.5 之间。

这样的目标听起来不够远大，然而 Winton 却发现**只要 16 个不相关的夏普比仅 0.5 的信号，就能产出一个夏普比为 2 且容量巨大的策略**———这是一种非常远大的野心!

Winton	More Experimental	More Observational
Portfolio construction	Combine 许多（可能 1000 个或更多）的高夏普、低容量信号	Combine 10 至 100 个夏普不高但没有相关性且高容量的信号
Hypotheses versus data	由数据驱动，因为能不断地在新数据集上尝试所以可以快速抛弃亏损的策略。	由假设驱动，然后寻找所需数据去测试正确性。
Explicability	没有必要理解为什么算法选择做出某笔特定的交易。任何一个信号都只是配置的很小部分且一旦失效可以被迅速关停。	了解策略的持仓非常重要。对一个信号的信心会被增强，如果有某种原理能合理解释信号的效果。
Back test length	长期回测是非必要的，因为信号的权重会跟随策略表现快速地被调整。	更长的回测（理想状态下 30-40 年）帮助建立对较慢信号的 performance and correlation properties 的信心。
Statistical aims	从近期大量的数据中提取信息	当可用数据受限时，做出可靠的推断
Statistical methods	由于对大量的输入数据的需求和不一定具有可解释性的结果的输出，因此成为机器学习技术的乐园。	虽也有机器学习的一席之地，但更多地聚焦于相对简单的数学技术，基于对数据和世界间更深刻关系的理解。
Selection bias	较少的担忧，因为可以对短期业绩快速作出反应。	一种主要的担忧。低夏普信号的业绩很难在短时间内评价，所以在研究阶段解决该 bias 至关重要。
Scientific inspiration	机器学习的应用和高性能计算的领域，包括图像和语音识别、自然语言处理。	季节、药学、重力波等各式各样低信噪比和高 Selection bias 风险的领域。

当然，追求 Sharpe ratio 不高是比较容易的，但难点是：

1. 确保这些 Sharpe ratio 在未来仍为正的
2. Statistical estimation error 是一个问题
3. 更致命的难点还有 Selection bias

关于 Selection bias 该如何刻画，可以想象 100 项随机的交易信号，它们根据定义是没有能力去预测市场的，但它们的回测表现将不会是精确的零而是一个分布，有一部分信号会看起来产生 0.3 甚至更高的夏普比。如果我们只选择历史上表现好的同时摒弃差的，我们就会有一个回测绝佳但是实盘的夏普比可能为零，甚至考虑交易成本后为负的投资策略。

Experimental 与 Observational 需要权衡，并不是一定要非此即彼，只是由此提供一个良好的框架。

附录 1st

记录一些知识点以帮助自己研究。

一、专有名词和理论补充

a) **IC (信息系数)：**代表因子预测股票收益的能力。
   - 计算方法：计算全部股票在调仓周期期初排名和调仓周期期末收益排名的线性相关度（Correlation）。
   - 计算股票池中，在 t-1 期的因子值和 t 期收益率的线性相关度。

$$IC = corr(f_{t-1}, r_t)$$

b) **IR (信息比率)：**代表因子获取稳定 Alpha 的能力。
   - 计算方法：IC 的多周期均值/IC 的标准方差。
   - 信息率 = 超额收益/为超额收益承担的额外风险
   - IR 是超额收益均值与标准差之比（一般指 IC 均值与标准差之比），每一个周期都会计算出一个 IC 值，IR 等于多个调仓周期的 IC 均值除以这些 IC 的标准差。

$$IR = \frac{\overline{IC}}{\sigma(IC)} = \frac{\text{（策略每日收益} - \text{基准每日收益）的年化均值}}{\text{年化标准差}}$$

c) **Ranked IC：**Average rank IC corresponds to the magnitude of the alpha.
   - 计算股票池中，在 t-1 期的因子排名和 t 期收益率排名的线性相关度。

$$Ranked\ IC = corr\left(order_{t-1}^{f}, order_{t}^{r}\right)$$

d) **Risk adjusted rank IC：**It measures the level and consistency of the alpha.

e) **计算 IC 的 t 值公式：**

$$t_{IC} = \frac{\overline{IC}\sqrt{n}}{\sigma(IC)} = \frac{\overline{IC}}{s.e.(IC)}$$

f) **冲击成本：**指的是投资品流动性不足带来的额外交易费用。
   - 对于流动性高的投资品，限价指令簿（limit order book）买一和卖一之间的价差（bid-ask spread）很小且两边的挂单量都足够，不带来太大的市场冲击。
   - 但如果投资品的流动性不足，那么为了完成交易，策略就势必会 walk the book（在一个方向上"收单"），直到完成我们的交易量需求。
   - 这个冲击成本和每笔交易时的具体流动性有关，因此回测中难以准确估计。

g) **Downside Risk 下行风险：**衡量了未来策略收益有可能低于预期目标的风险

$$Downside\ Risk = \sqrt{260} \times \sqrt{\frac{\sum_{i=1}^{T}\left(R_i - R_f\right)^2}{T-1}}, R_i < R_f$$

其中R_i为策略每日回报率，R_f为一年期定存利率/365，T 为计算区间包含的交易天数。

h) 另类数据被 JPM 分为：

个人	商业流程	传感器
社交媒体	交易数据	卫星
新闻和评论	企业数据	地理位置
网络索索和个人数据	政府代理数据	其他传感器

i) 一致预期：指基于各券商分析师的调查的上市公司盈利预期数据平均值。

j) Sector neutral：投资组合的在各个板块的权重和基准是一致的，也就是说我们并不 bet on sector，而是关注于每个 sector 内部的所有股票的构成。

k) 特征选择：通常我们根据 a)特征是否发散和 b)特征与目标的相关性来选择特征。

- Filter：按照发散性或者相关性对各个特征进行评分，设定阈值或者待选择阈值的个数进行特征选择。
- Wrapper：根据目标函数（通常是预测效果评分），每次选择若干特征，或者排除若干特征。
- Embedded：先使用某些机器学习的算法和模型进行训练，得到各个特征的权值系数，根据系数从大到小选择特征。类似 Filter 但通过训练确定特征优劣。

MSCI 中国指数：由一系列国家指数、综合指数、境内以及非境内指数组成，提供给国内外投资者，包括 QDII 和 QFII 持牌机构多样化的选择。指数总市值达 1.21 万亿美元，覆盖了全球范围内中国股票市值的 85%。当然，是除 A 股之外的市值。

全球超过 90%的机构股票资产以 MSCI 指数为基准，相关资产价值总额超过 10 万亿美元。有超过 750 只 ETF 基金直接跟踪 MSCI 系列指数。

共计有 1.5 万亿美元的资金以 MSCI 新兴市场指数为基准；约有 2000 亿美元的 ETF 指数基金直接跟踪 MSCI 新兴市场指数和 MSCI 中国指数。

根据彭博数据，目前直接跟踪 MSCI 中国指数的指数和公募基金有 49 支，规模合计超过 140 亿美元。其中规模最大的基金单支规模就近 40 亿美元。可分为：

- 旗舰指数：MSCI 中国指数（MSCI China Index）及其细分指数
- 综合指数：MSCI 中国全股票指数（MSCI China All Share Index）、MSCI 金龙指数（MSCI Golden Dragon Index）、MSCI 中华指数（MSCI Zhong Hua Index）等
- 纯境内指数：MSCI 中国 A 股指数（MSCI China A Index）、MSCI 中国 A 股（国际）指数（MSCI China A International Index）等
- 纯境外指数：MSCI 海外中国指数（MSCI Overseas China Index）等

MSCI 中国 A 股指数[11]（MSCI China A Index）：MSCI 为 A 股专设的指数。截止 19 年 4 月底，覆盖了沪深市场 865 支大盘股和中盘股，相当于沪深 300 指数的扩充版。目前总市值 1.7 万亿美元，比 MSCI 中国指数规模还要大。

但因为这个指数没有考虑海外投资者的投资限制，而国内机构又大多跟踪境内指数公司的指数，因此目前跟踪该指数的资金规模很小。根据彭博的最新数据，当前有 14 支指数基金直接跟踪 MSCI 中国 A 股指数，总资金规模约为 10 亿美元。

[11] **Source:** https://zhuanlan.zhihu.com/p/57968907

Inflated Sharpe Ratio：

即使因子的 ideas 不错，但最好的回测结果仍可能一部分仅是因为运气，真实的 Sharpe ratio 还是容易被高估[12]，导致一种虚假的高夏普比。

Bailey and Lopez de Prado (2012, 2014) 专门就 inflated Sharpe Ratio 进行了探讨。他们假设不同参数的策略的夏普率满足均值为 E[SR]、方差为 V(SR) 的正态分布。在上述假设下，N 组不同参数中样本内最大的夏普率的期望满足（式中 γ 是欧拉-马斯刻若尼常数）：

$$\begin{aligned} \mathrm{E}[\mathrm{SR}_{\max}] &\approx \mathrm{E}[\mathrm{SR}] \\ &+ \sqrt{\mathrm{V}(\mathrm{SR})}\left((1-\gamma)Z^{-1}\left[1-\frac{1}{N}\right]+\gamma Z^{-1}\left[1-\frac{1}{N}e^{-1}\right]\right) \end{aligned}$$

该关系式表明，样本内的最大夏普率随 N 增大和 V(SR) 增大。假设 V(SR) = 1，则我们只需要测试 100 组设定，样本内的虚高夏普率就高达 2.5，尽管它对应的 null hypothesis 是该策略真实夏普率为 0。这就是不考虑多重检验的危害。

即使在许多机构文化中，由挑出最佳回测效果的因子带来的 selection bias 依然是根深蒂固的，因为雇员总是想把最好看的结果展示给 managers.

但比起样本内的惊艳效果、追求最小的 P-value，我们更应该看重研究的质量、对市场的正确理解，不然的话就会像在学术顶级期刊中，很难找到高研究质量缺低显著性的因子。

虽然实际的交易信号不是随机产生的，但现实情况仍很相似，同样无法确定这些因子未来继续有效。或许也牵涉因子的动态变化，过往好的因子可能正变得无效，甚至彻底反转。

Figure 8 Price Momentum Factor in the US

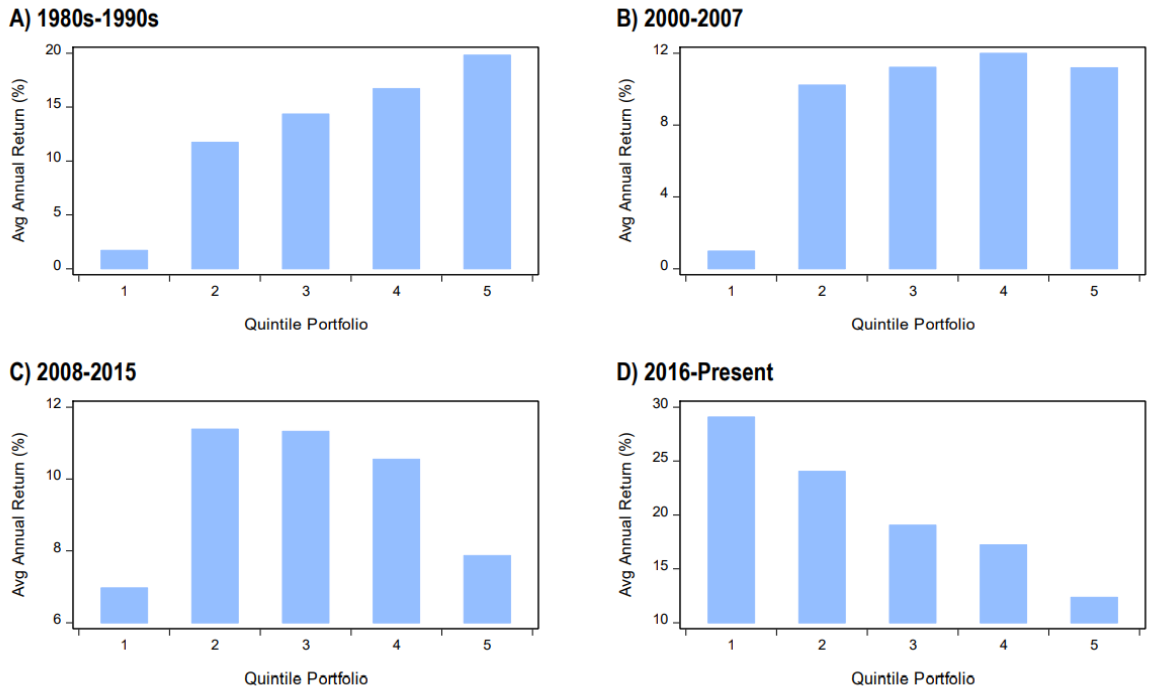

Sources: Bloomberg Finance LLP, FTSE Russell, S&P Capital IQ, Thomson Reuters, Wolfe Research Luo's QES

[12] 类似于**多重检验**：我们测试一个策略的许多组参数，或者选很多个因子时，仅仅依靠运气，这些参数或者因子中效果最好的那个就能在样本内获得很高的夏普比（即 inflated Sharpe Ratio）。

附录 2nd

正文提及较大型图表的补充。

二、 图表补充

1. Winton 原英文表格：

	More Experimental ←	→ More Observational
Portfolio construction	Combine many (possibly 1,000s or more) high Sharpe ratio, low-capacity signals.	Combine 10 to 100 lower Sharpe ratio signals that are uncorrelated and have high capacity.
Hypotheses versus data	Data-driven, since the ability to discard loss-making strategies quickly allows for rapid experimentation on new datasets.	Form a hypothesis and then search for the data required to test it.
Explicability	No need to understand why the algorithm chooses to make a particular trade. Any one signal will only have a small allocation and will be switched off quickly if it stops working.	Understanding why the strategy takes its positions is vital. Confidence in a signal can increase if there is a rationale for why it works.
Back test length	Long backtests are unnecessary as signal weights are adjusted rapidly in line with performance.	Longer backtests (ideally 30 to 40 years) help to build confidence in performance and correlation properties of slower signals.
Statistical aims	Extracting information from vast quantities of recent data.	Making reliable inferences when the data available is limited.
Statistical methods	Rich playground for machine learning techniques, which require lots of input data and do not necessarily provide explicable outputs.	Some scope for machine learning, but more focus on simpler mathematical techniques based on a deeper understanding of the relationship between the data and the world.
Selection bias	Less of a concern given the ability to respond to short-term performance.	A major concern. The performance of low Sharpe ratio signals cannot be judged immediately so it is vital to mitigate biases at the research stage.
Scientific inspiration	The application of machine learning and high-performance computing to domains, including image and voice recognition, and natural language processing.	Medicine, gravitational waves, extrasolar planets, etc. Fields that are characterised by low signal-to-noise ratios and a high risk of selection bias.

2. Wind CITICS-ICS 行业划分

行业中性 Sector Neutralization(P43-36):所用的 Wind CITICS-ICS 行业分类:

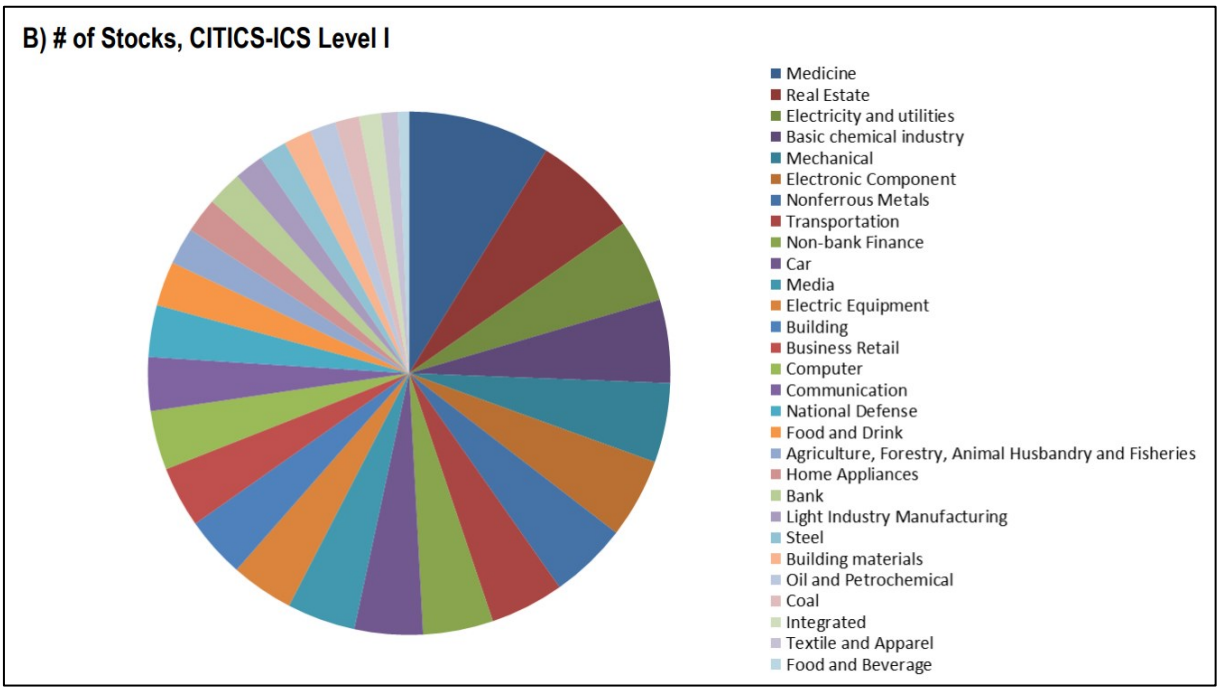

之前我处理出的中信一级行业划分:

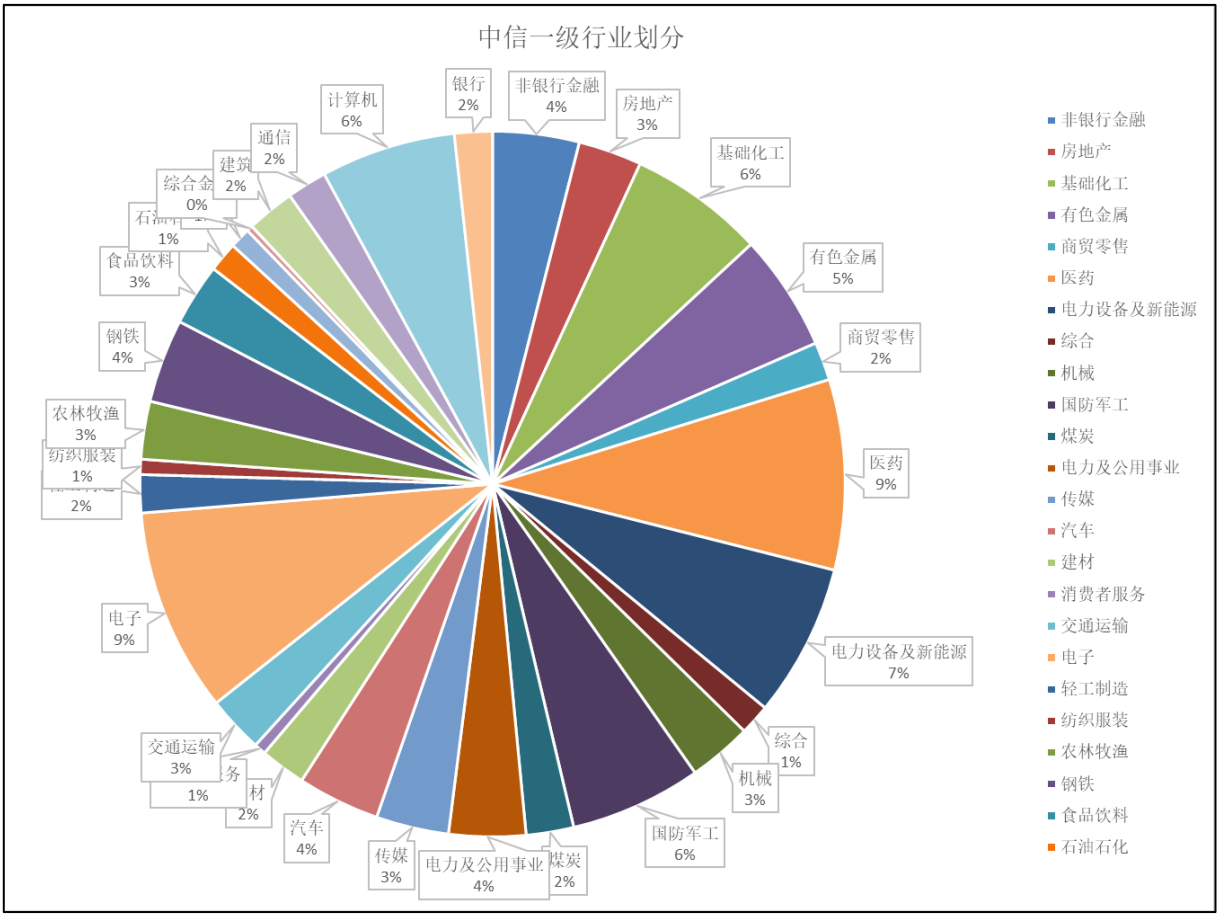

3. “A Backtesting Protocol in the Era of Machine Learning”中的 Bullet points：

Seven-Point Protocol for Research in Quantitative

1. **Research Motivation 研究动机**
   a) Does the model have a solid economic foundation?
   b) Did the economic foundation or hypothesis exist before the research was conducted?

2. **Multiple Testing and Statistical Methods 多重检验&统计方法**
   a) Did the researcher keep track of all models and variables that were tried (both successful and unsuccessful) and are the researchers aware of the multiple-testing issue?
   b) Is there a full accounting of all possible interaction variables if interaction variables are used?
   c) Did the researchers investigate all variables set out in the research agenda or did they cut the research as soon as found a good model?

3. **Data and Sample Choice 数据与样本抉择**
   a) Do the data chosen for examination make sense? And, if other data are available, does it make sense to exclude these data?
   b) Did the researchers take steps to ensure the integrity of the data?
   c) Do the data transformations, such as scaling, make sense? Were they selected in advance? And are the results robust to minor changes in theses transformations?
   d) If outliers are excluded, are the exclusion rules reasonable?
   e) If the data are winsorized, was there a good reason to do it? Was the winsorization rule chosen before the research was started? Was only on winsorization rule tried (as opposed to many)?

4. **Cross-Validation 交叉验证**
   a) Are the researchers aware that true out-of-sample tests are only possible in live trading?
   b) Are steps in place to eliminate the risk of out-pf-sample “iterations” (i.e., an in-sample model that is later modified to fit out-of-sample data)?
   c) Is the out-of-sample analysis representative of live trading? For example, are trading costs and data revisions taken into account?

5. **Model Dynamics 模型动力学**
   a) Is the model resilient to structural change and have the researchers taken steps to minimize the overfitting of the model dynamics?
   b) Does the analysis take into account the risk/likelihood of overcrowding in live trading?
   c) Do researchers take steps to minimize the tweaking of a live model?

6. **Complexity 复杂度**
   a) Does the model avoid the curse of dimensionality?
   b) Have the researchers taken steps to produce the simplest practicable model specification?
   c) Is an attempt made to interpret the predictions of the machine learning model rather than using it as a black box?

7. **Research Culture 研究文化**
   a) Does the research culture reward quality of the science rather than finding the winning strategy?
   b) Do the researchers and management understand that most tests will fail?
   c) Are expectations clear (that researchers should seek the truth not just something that works) when research is delegated?

Resource: Arnott, Harvey, and Markowitz (2019)

Reference

[1] Wang, S., Luo, Y., Alvarez, M., Jussa, J., Rohal, G. [2017c]. "The Silk Road to China", Wolfe Research Luo's QES, December 1, 2017

[2] Luo, Y., Jussa, J., and Wang, S. [2017b]. "Signal Research and Multifactor Models", Wolfe Research Luo's QES, February 16, 2017

[3] Luo, Y., Jussa, J., and Wang, S. [2017a]. "The Big and The Small Sides of Big Data", Wolfe Research Luo's QES, February 8, 2017

[4] Luo, Y., Jussa, J., and Wang, S. [2017c]. "Style Rotation, Machine Learning, and The Quantum LEAP", Wolfe Research Luo's QES, February 24, 2017

[5] "Experiment and Observation in Quantitative Investment", Winton Capital, available here.

[6] Arnott R D, Harvey C R, Markowitz H. A Backtesting Protocol in the Era of Machine Learning[J]. ***Social Science Electronic Publishing***.

[7] Hsu J, Viswanathan V, Wang M, et al. Anomalies in Chinese A-Shares[J]. ***The Journal of Portfolio Management***, 2018, 44(7):108-123.

[8] Chen X, Kim K A, Tong Y, et al. On the predictability of Chinese stock returns[J]. ***Pacific-Basin Finance Journal***, 2010, 18(4):403-425.

[9] Dechow P M, You H. Understanding the Determinants of Analyst Target Price Implied Returns[J]. ***The Accounting Review***, 2020.